

- 本文提出了将深度学习中的 LSTM 算法应用到卫星轨道预报中，提高了轨道预报的精度。
- 传统的轨道预报方法建立在对于卫星动力学的精确建模的基础上，使用数值积分法或者解析方法进行轨道预报。
- 对于各种轨道的卫星，不同摄动力的影响也不尽相同，例如对于低轨卫星，大气阻力摄动产生的影响比较明显，而对于中高轨道卫星，太阳光压摄动的影响较为明显。
- 在计算大气阻力摄动的过程中，大气的密度，迎风面积，目标与大气相对于地心速度的差值都是影响摄动大小的因素，然而现有大气密度模型的精度不高，大约在 5%~10%之间[1]。太阳光压的计算需要考虑地球反射、地影、月影等因素，在定轨过程中产生大量的时变参数，长期累积也会影响预报精度。
- 深度神经网络作为一种新型的建模工具，能够拟合高阶、非线性的模型，不需要考虑实际系统的物理意义，能够直接得到输入与输出之间的映射关系
- 将卫星的轨道抽象为时间的序列，通过长短期记忆网络方法对卫星轨道进行预报，能够避免建立动力学模型，在大幅度简化预报复杂性的基础上，理论上能够得到更高的精度。
- 目前卫星轨道预报方法都建立在知道卫星的精确动力学建模的基础上，提高精度的方法主要就是提高动力学建模的精度。
- 分析卫星在轨运行过程中受到的摄动力对于精确建模具有重要意义，卫星在轨摄动主要分为地球非球形引力摄动、第三体引力摄动、大气阻力摄动、太阳光压摄动等，在建立卫星轨道动力学模型的过程中首先要对各个摄动力进行分析建模。
- 定轨的定义就是使用观测得到的数据确定卫星的轨道根数
- 深度神经网络是模仿生物大脑神经元之间的联系，建立的一种映射模型。在信息经过每一层神经元的过程中，信息所包含的特征一步步被提取，最后能够得到期望的输出[22]。
- 对于已知卫星轨道的卫星，对卫星未来一段时间内的位置进行预测，卫星轨道预测方法的核心是求解微分方程的初值。解析法关注点主要在于尽量的精确化卫星动力学建模，使得得到的方程尽可能的接近于实际卫星在轨运动的方程，是一个优化模型的过程。数值法通过数值积分求解卫星在轨运行的状态方程，预报精度主要与数值积分算法的精度有关，通过对阶段误差的计算估计大致的预报精度。
- 解析法由于受到模型建模的影响，精确度不是很高，但是由于其在分析卫星受力时比较方便，并且运算速度很快，占用硬件资源小，所以目前卫星在轨的预测普遍使用的是解析法。
- 常用的解析轨道模型是通过北美防空司令部提供的两条轨道根数(TLE)进行预测，TLE 通过特定方法去掉了周期项的干扰，得到了平均轨道根数。
- 数值法通常分为单步法和多步法。单步法应用范围比较广泛，稳定性较好但是计算速度较慢。多步法运算速度快，但是稳定性较差。
- 随着神经网络与深度学习这几年的发展，其在高维度非线性的场合下的应用越来越广泛。由于不需要知道输入与输出之间的具体关系与参数，只需要通过训练神经网络得到两者之间的映射，省却了对卫星轨道精确建模的过程，能够大大提高预报的准确性。
- 时间序列定义为一组根据时间顺序进行排列的观测值。对于卫星而言，观测得到的轨道数据也是依据时间先后排列的，卫星轨道可以抽象成六个连续时间序列。时间序列预测是利用过去一段时间内的某个变量的取值作为输入，预测未来一段时间内的该变量的值。
- 运用 LSTM 算法进行时间序列预测属于有监督学习，所以数据预处理的过程中需要将数据集分为训练集和测试集。其中训练集为了训练神经网络模型，得到输入与输出之间的映射关系。测试集为了验证所得到的神经网络是否满足预测的要求，通过将测试集的输出与神经网络得到的输出进行比较，检验得到的神经网络。

- 由于 LSTM 算法对于输入输出数据有归一化要求，所以在将数据送入网络之前需要进行归一化处理，将数据等比例放缩为 -1 到 1 之间的数。
- 为了解决梯度消失问题，科学家提出了长短期记忆网络(LSTM)，通过加入了专门的记忆模块，代替了 RNN 中的隐藏节点，能够确保梯度在多层传输的过程中不消失，使得 RNN 算法能够真正的投入应用中。LSTM 算法问世以来，在时间序列预测领域有了广泛的应用并得到了良好的成绩。
- LSTM 算法中的记忆模块，又称为记忆单元，可以将信息从序列的初始位置传递到序列的末端，可以做到让神经网络记住需要记住的重要信息。

首先初始化网络，设定初始偏置，根据公式(4-17)至(4-27)进行前向运算，得到当前参数下的神经网络输出值。之后确定目标函数，计算实际值与真实值之间的误差，并构造误差函数，最后根据梯度下降原则，更新网络的权重以及偏置。在应用梯度下降法进行参数更新的过程中，误差的反向传播分为两个层面：时间层面与空间层面。空间上将参数误差在层之间传播，从输出层到输入层；时间上将误差沿着时间顺序进行反向传播，由当前时刻开始计算各个时刻的误差。

重复迭代三个过程，直到网络误差小于给定值。

具体每一次迭代运用到的公式情况为：

根据 LSTM 前向运算公式(4-17)到(4-27)，计算出当前输入所在当前权值情况下对应的预期输出；

根据公式(4-28)计算损失函数；

从序列长度 T 到 1 迭代计算公式(4-29)到(4-35)中的残差；

根据公式(4-36)到(4-44)计算各个连接层需要更新的权重的偏导；

根据公式(4-45)计算各个更新后的参数。

使用长短期记忆网络进行卫星轨道预测的流程图为：

-

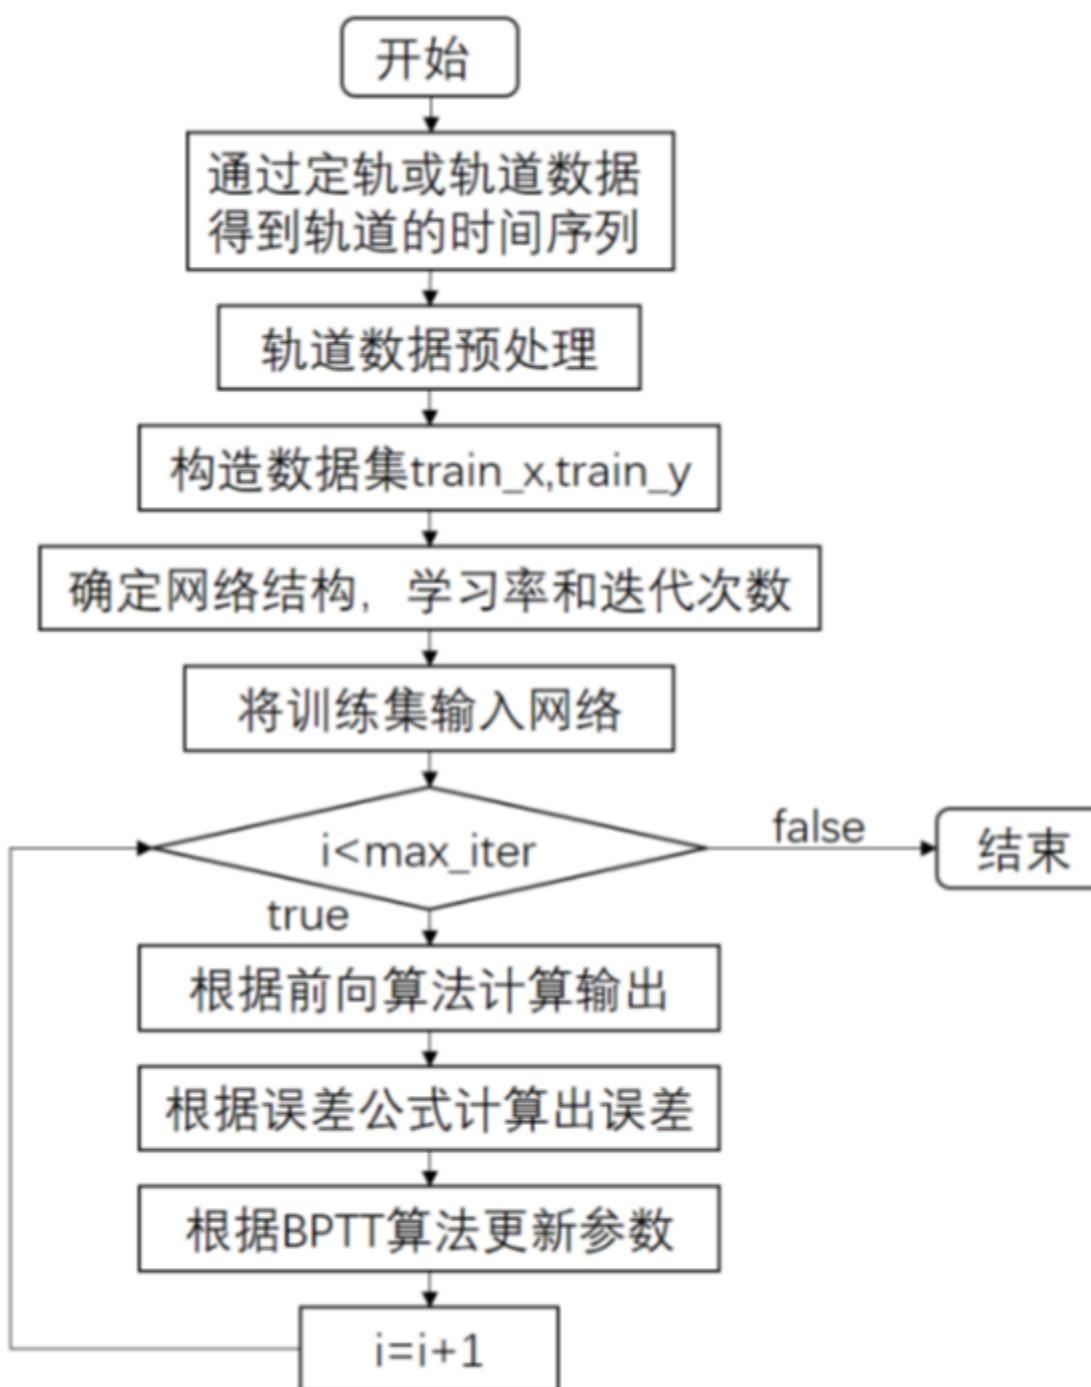


图 4-5 LSTM 轨道预测算法流程图

- 萤火虫算法是 2008 年，有英国剑桥大学学者提出的一种群体智能优化算法。该算法依据自然界中萤火虫的习性以及行为方式，进行数学抽象得到。相较于其他群体智能优化算法，萤火虫算法需要调节的参数较少，模型简单，易于实现等特点。而且在诸多试验的表现中，萤火虫算法表现出速度快，擅长解决多模态问题等优点。所以虽然萤火虫算法提出不久，但是已经在诸多领域得到了广泛的应用。将萤火虫算法应用于长短期记忆网络的参数优化，并将优化后的 LSTM 算法应用于卫星轨道预测中，验证可行性并与 BPTT 算法进行比较。
-

光在空气中传播的过程中，其光的强度与传播距离有关。空间中某一点的光强度与其到光源的距离的平方成反比，并且光在空气中传播的过程中会随着距离的增加变弱。所以萤火虫之间感受到对方的光强度与距离和介质的衰减系数有关，根据此可以提出适用于萤火虫算法的准则：

- (1) 萤火虫之间的相互引力与其亮度呈正比关系。对于任意的两只萤火虫，较暗的一只会被较亮的吸引，并向亮度高的萤火虫移动，而亮度较高的萤火虫随机运动；
- (2) 萤火虫的亮度代表了准则函数的值。

萤火虫算法的主题思想就是，首先将解空间中的点抽象成萤火虫个体，然后将用自然界中萤火虫之间的吸引准则模拟优化过程中的位置更新，在此期间将解空间中点的函数值抽象为萤火虫的亮度，最后进行迭代，得到全局最优解。